Installationsguide: Zotero RAG-Plugin

Anbindung an lokale Server via TU Darmstadt VPN

TECHNISCHE UNIVERSITÄT DARMSTADT

Wintersemester 25/26

Vorab: Wichtiger Hinweis zur WebDAV-Nutzung

Dieser Guide führt Sie durch die Installation des Zotero RAG-Plugins. Prüfen Sie bitte Ihre aktuelle Konfiguration:

- **Szenario A:** Sie nutzen bisher **keinen** eigenen WebDAV-Server. Fahren Sie direkt mit Abschnitt 1 fort.
- **Szenario B:** Sie nutzen bereits einen eigenen WebDAV-Server. Erstellen Sie bitte einen **zweiten Zotero-Account** und loggen Sie sich mit diesem ein, um Synchronisationskonflikte zu vermeiden. Speichern Sie die neuen Zugangsdaten ggf. in einem Passwort-Manager.

1 Systemzugang und VPN-Konnektivität herstellen

Bevor das Zotero-Plugin genutzt werden kann, muss die Netzwerkkonnektivität zum internen Server der TU Darmstadt gewährleistet sein.

- **Freischaltung beantragen:** Kontaktieren Sie die zuständigen Administratoren um Ihre TU-ID und Ihren Namen für das VPN-System autorisieren zu lassen.
- **Cisco Secure Client konfigurieren:** Öffnen Sie den Cisco Secure Client und geben Sie als Zieladresse `fwlt.net.hrz.tu-darmstadt.de` ein.
- **Authentifizierung:** Melden Sie sich mit Ihren regulären TU-Credentials (Moodle-Benutzername und Passwort) an.
- **Zwei-Faktor-Authentifizierung (2FA):** Bestätigen Sie den Login-Vorgang abschließend über Ihre verbundene Authenticator-App. Die VPN-Verbindung sollte nun aktiv sein.

2 Plugin-Installation und Backend-Synchronisation

In dieser Phase wird das Plugin in Zotero integriert und die Dateisynchronisation auf den lokalen Server umgestellt.

- **Grundvoraussetzung:** Öffnen Sie Zotero und stellen Sie sicher, dass Sie mit Ihrem (ggf. neuen) Zotero-Account angemeldet sind.
- **Plugin hochladen:** Navigieren Sie in der Menüleiste zu `Werkzeuge` > `Plugins` [1]. Klicken Sie auf das Zahnrad-Symbol oben rechts, wählen Sie „Add-on aus Datei installieren...“ und laden Sie die bereitgestellte Build-Datei des RAG-Plugins hoch.

[1] Der bereitgestellte Screenshot ist von MacOS, allerdings ist die Navigation auf Windows analog dazu.

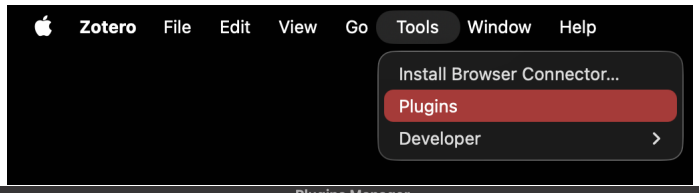

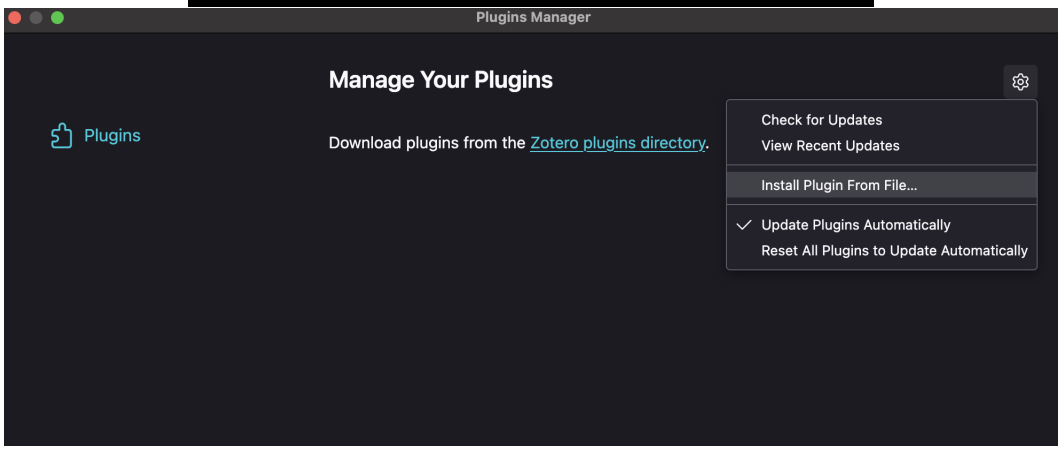

- **WebDAV konfigurieren:** Wechseln Sie in die Zotero-Einstellungen (`Bearbeiten` > `Einstellungen`) und öffnen Sie den Reiter `Sync`.
- **Synchronisations-Parameter setzen:**
  - Stellen Sie „Dateianhänge in Meine Bibliothek synchronisieren mit“ auf **WebDAV** um.
  - Tragen Sie als URL `http://192.168.2.252:8080/webdav` ein.
  - Benutzername und Passwort können beliebig gefüllt werden (z. B. „albert“ und ein beliebiges Passwort), da die eigentliche Authentifizierung bereits über den aktiven VPN-Tunnel abgewickelt wird.

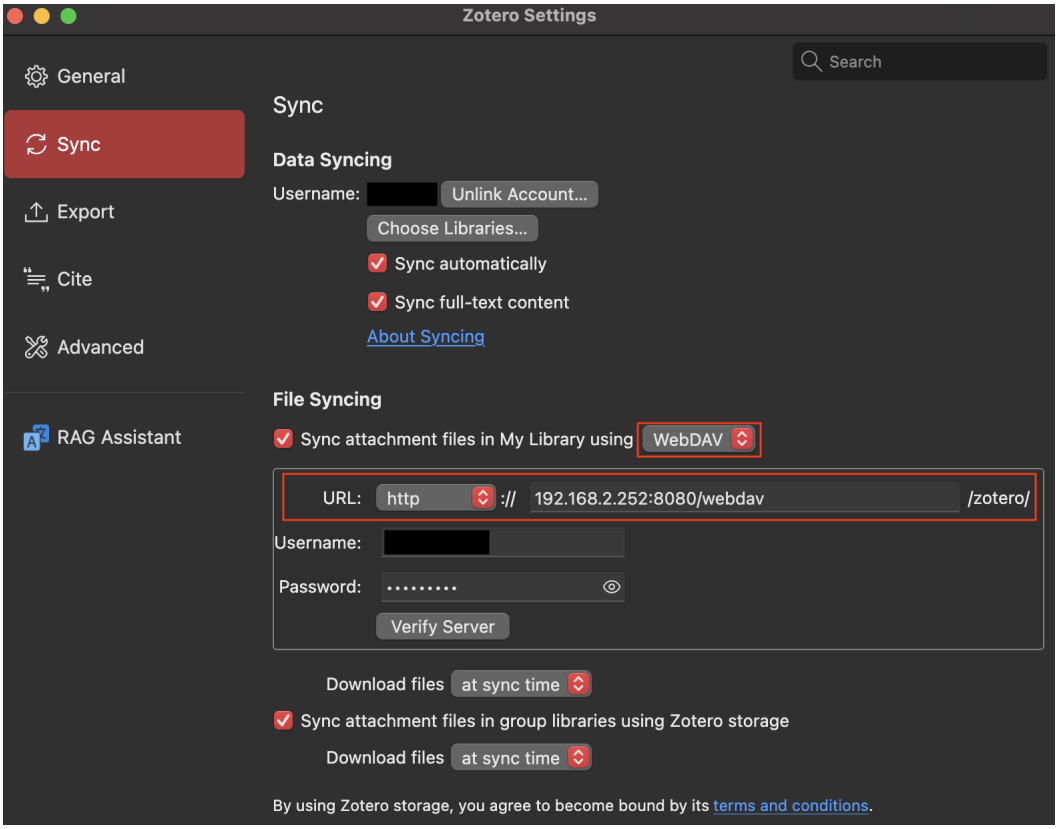

3 LLM- und RAG-Pipeline initialisieren

Zuletzt muss das Plugin auf die richtige Schnittstelle für das Sprachmodell ausgerichtet werden.

- **API-Routing:** Navigieren Sie in den Zotero-Einstellungen zum neuen Reiter `RAG Assistant`.
- **Base URL eintragen:** Tragen Sie unter „API Base URL“ die Serveradresse `http://192.168.2.252:8080` ein.
- **Prompts laden:** Scrollen Sie ganz nach unten und klicken Sie auf **Reload Prompts**. Dieser Schritt ist essenziell, um die System Instructions vom Server abzurufen.
- **Speichern (Kritisch):** Falls Sie die geladenen Prompts an Ihre Bedürfnisse anpassen, müssen Sie zwingend auf **Save Prompts** klicken, um die Änderungen dauerhaft zu übernehmen.
- **Chat outputs speichern (Optional):** Falls Sie ihre Chats lokal auf ihrem Gerät speichern wollen, können sie hier einen Speicherort auswählen.

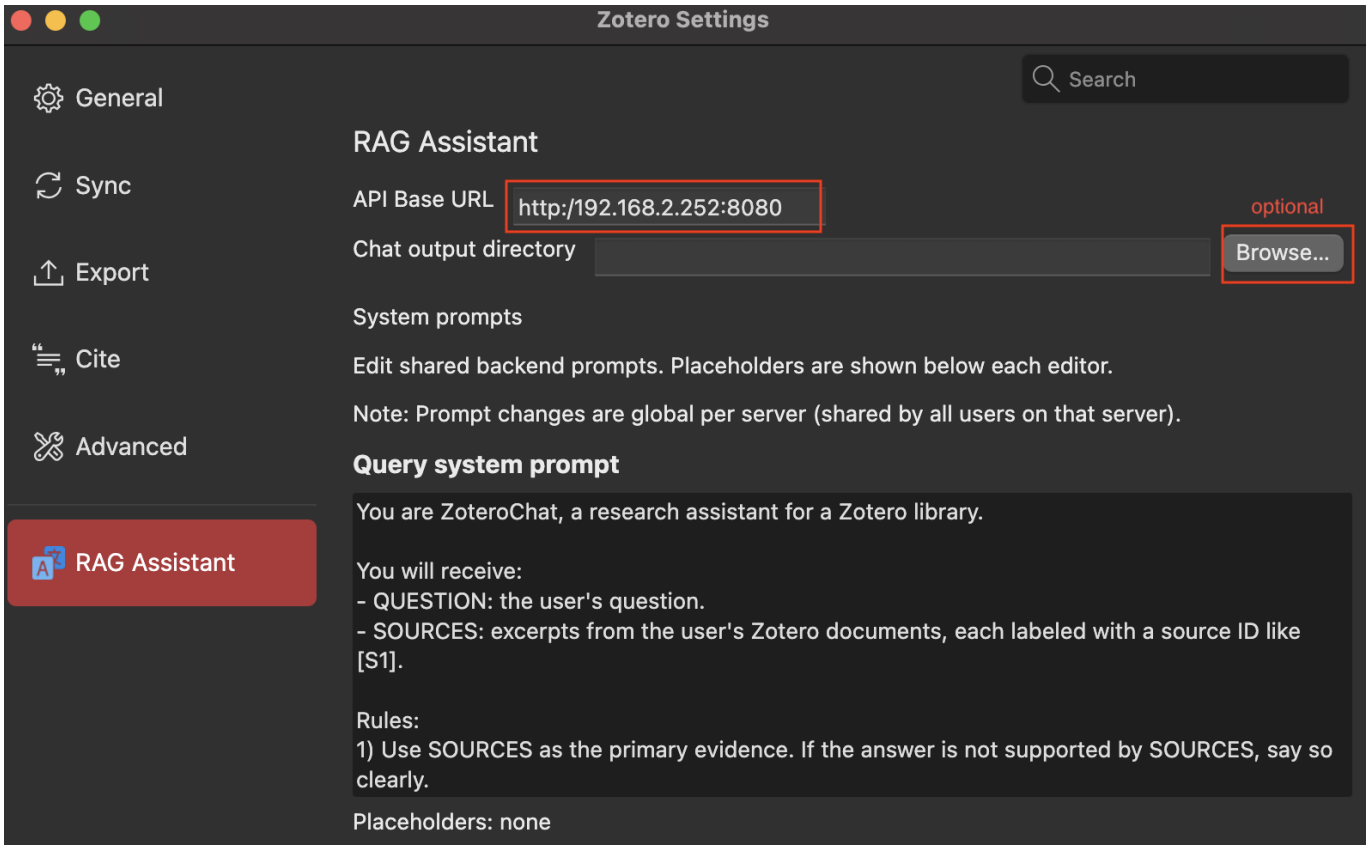

Für den gesamten Installationsprozess gilt: Möglicherweise müssen Sie Zotero zwischendrin neu starten.

4 Nutzung des Plugins

Nach erfolgreicher Einrichtung ist das System einsatzbereit. Öffnen Sie ein beliebiges Paper in Zotero (Doppelklick auf das PDF). In der rechten Seitenspalte finden Sie nun das neue Icon für das Plugin. Darüber können Sie das Chat-Interface nutzen. Die RAG-Pipeline nutzt alle verfügbaren Dokumente als Quelle, nicht nur das welches Sie offen haben. Dementsprechend muss ein Dokument genau benannt werden, wenn Sie zum Beispiel nur ein spezifisches Paper zusammenfassen wollen.

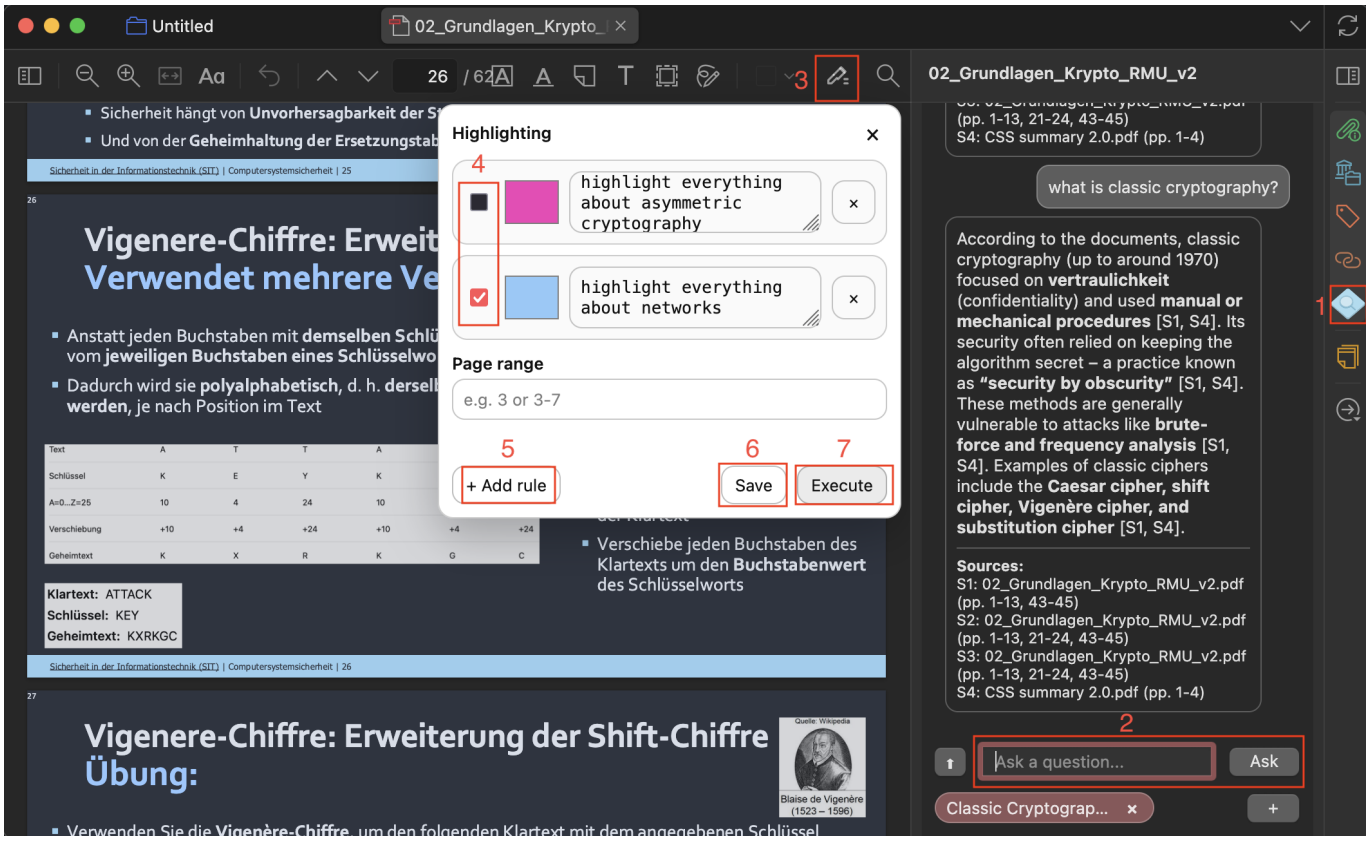

1. Drücken Sie diesen Knopf um zum Chat-Interface zu navigieren.
2. Dies ist ein Texteingabefeld für Abfragen. Nach Start einer Frage können Sie auf **Stop** drücken um sie abzubrechen. Unter der Textbox können Sie verschiedene Chats hinzufügen und umbenennen.
3. Drücken Sie diesen Knopf um das Annotation Tool zu öffnen.
4. Hier können Sie Haken setzen wenn Sie möchten, dass eine Regel in der nächsten Iteration ausgeführt wird. Somit müssen Sie Regeln nicht löschen, wenn Sie sie in der Zukunft möglicherweise wiederverwenden möchten.
5. Hier können Sie neue Regeln hinzufügen.
6. Wenn Sie Änderungen gemacht haben aber noch nicht die Annotations ausführen möchten können Sie auf **Save** drücken um zu speichern.
7. Hier können Sie die automatischen Annotations ausführen. Alle Regeln, bei denen ein Haken gesetzt ist werden beachtet und es werden nur Stellen in der angegeben **page range** markiert (oder im gesamten Dokument wenn nichts spezifiziert ist). Ein kleinerer Seitenumfang führt selbstverständlich zu kürzerer Wartezeit. Wie bei dem Chat-Interface können Sie auch auf **Stop** drücken um den Vorgang abzubrechen. Sie können während der Ausführung die **active requests** und die **processed chunks** einsehen um ihre mögliche Wartezeit etwas einschätzen zu können.